

Московский государственный университет имени М. В. Ломоносова  
Факультет космических исследований

---

Курсовая работа  
студента 402 группы  
Шигина Глеба Сергеевича

Трансформация данных в GLM моделях

Научный руководитель:  
с.н.с., к.ф.-м.н.  
Шкляев Александр Викторович

Москва, 2022

# Содержание

<b>1 Введение</b>	<b>2</b>
<b>2 Трансформация данных</b>	<b>2</b>
2.1 Трансформация только зависимой переменной при помощи inverse response plot . . . . .	2
2.1.1 Inverse response plot . . . . .	3
2.1.2 Выбор степенного преобразования . . . . .	4
2.2 Трансформация только зависимой переменной при помощи преобразования Бокса-Кокса . . . . .	5
2.3 Трансформация только предиктора методом Бокса-Кокса . . . . .	6
2.4 Трансформация и предиктора, и зависимой переменной . . . . .	6
<b>3 Заключение</b>	<b>7</b>
<b>А Многомерное преобразование Бокса-Кокса</b>	<b>7</b>
<b>В Графики</b>	<b>8</b>

# 1 Введение

ТВА

## 2 Трансформация данных

Существуют классы задач, для которых мы знаем, что математическое ожидание  $E(Y|X)$  является линейной функцией от  $X$ . Это может быть теория, подкрепленная экспериментальными данными [Weisberg et al., 1978], либо статистическая информация о данных. Например, пусть  $y_i$  и  $x_i$  – выборки их нормальных распределений со средними  $\mu_X, \mu_Y$  соответственно, дисперсиями  $\sigma_X^2, \sigma_Y^2$  соответственно и корреляцией  $\rho_{XY}$ . Тогда можно показать (см. [Berger and Casella, 2001, стр. 550]), что

$$y_i | x_i \sim N\left(\mu_Y - \rho_{XY} \frac{\sigma_Y}{\sigma_X} \mu_X + \rho_{XY} \frac{\sigma_Y}{\sigma_X} x_i, \sigma_Y^2(1 - \rho_{XY}^2)\right). \quad (1)$$

Это можно переписать как  $y_i | x_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$ , где

$$\beta_0 = \mu_Y - \rho_{XY} \frac{\sigma_Y}{\sigma_X} \mu_X, \beta_1 = \rho_{XY} \frac{\sigma_Y}{\sigma_X}, \sigma^2 = D(Y|X) = \sigma_Y^2(1 - \rho_{XY}^2), \quad (2)$$

то есть мы получили линейную регрессию  $Y$  по  $X$ :

$$E(Y|X = x_i) = \beta_0 + \beta_1 x_i. \quad (3)$$

Однако, у нас не всегда есть возможность узнать истинную зависимость зависимой переменной от предикторов. Нам необходимо понять, какие преобразования бывают и как выбрать среди них наилучшее.

Для удобства на данном этапе ограничимся одним **предиктором  $X$  и зависимой переменной  $Y$** .

### 2.1 Трансформация только зависимой переменной при помощи inverse response plot

Предположим, что истинная регрессионная модель  $Y$  по  $X$  имеет вид:

$$Y = g(\beta_0 + \beta_1 X + \varepsilon), \quad (4)$$

где  $g$  – некоторая функция, вообще говоря, нам неизвестная. Модель (4) может быть приведена к линейному виду путем преобразования  $Y$  с помощью обратной функции  $g^{-1}$ :

$$g^{-1}(Y) = \beta_0 + \beta_1 X + \varepsilon. \quad (5)$$

Например, если  $Y = \log(\beta_0 + \beta_1 X + \varepsilon)$ , то  $g(x) = \log(x)$ , значит  $g^{-1}(x) = \exp(x)$ , и  $\exp(Y) = \beta_0 + \beta_1 X + \varepsilon$ .

В данной работе в качестве способа получения оценки  $g^{-1}$  предлагается рассмотреть метод обратного отклика (*inverse response plot*) с подбором функции из степенного семейства (*power family*), включающим в себя семейство преобразований Бокса-Кокса.

### 2.1.1 Inverse response plot

В работе [Cook and Weisberg, 1994] было показано, что если  $X$  имеет эллиптически симметричное распределение (что является менее жестким ограничением, чем нормальность), то  $g^{-1}$  можно оценить из scatter plot'a, где по горизонтальной оси откладываются истинные значения  $y$ , а по вертикальной – значения  $\hat{y}$ , полученные из регрессии на исходных данных:  $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ . Такой график называют **inverse response plot**.

### Пример

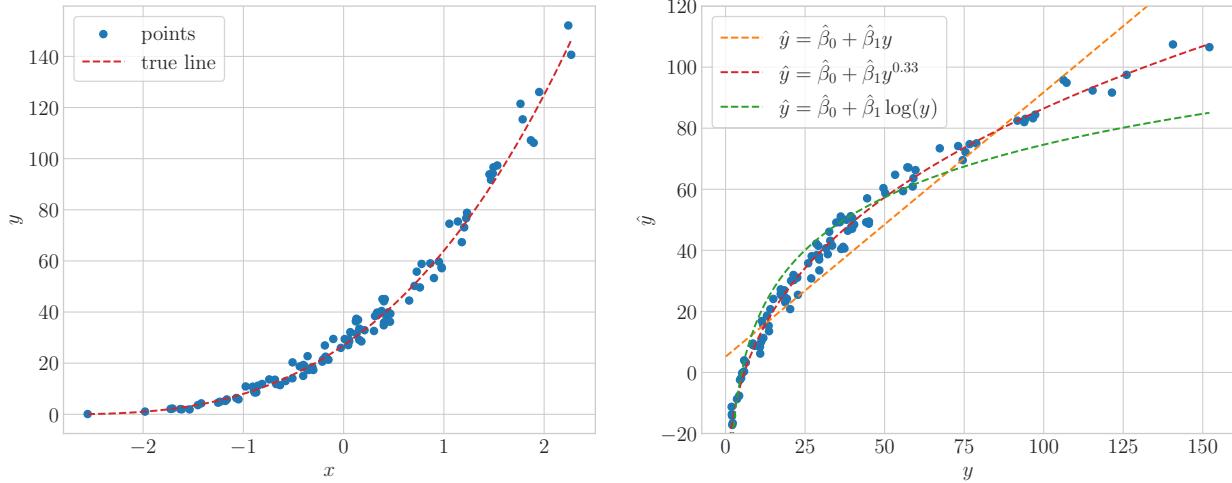


Рис. 1: Scatter plot  $Y$  от  $X$  (слева) и inverse response plot (справа)

Пусть  $X \sim N(0, 1)$ ,  $\varepsilon \sim N(0, 0.1)$ ,  $Y = (3 + X + \varepsilon)^3$ . Была построена выборка размера  $N = 100$ . Получившуюся зависимость можно увидеть на рисунке 1. Построим линейную регрессию  $y$  по  $x$  без преобразования данных. Получим некоторые оценки  $\hat{y}$ . Inverse response plot можно также увидеть на рисунке 1. Помимо точек, на графике присутствуют три пунктирные кривые – они показывают результаты линейных регрессий  $\hat{y}$  по  $y$ ,  $y^{1/3}$  и  $\log(y)$  соответственно. Видно, что кривая  $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 y^{1/3}$  наиболее близка к исходным точкам. Это ожидаемо, так как из построения  $Y$  следует, что искомое нами преобразование для  $Y$  имеет вид  $g^{-1}(Y) = Y^{1/3}$ .

### 2.1.2 Выбор степенного преобразования

**Семейство преобразований** (*transformation family*) – это параметризованное множество преобразований, где каждому значению параметра (или параметров) отвечает некоторый уникальный представитель семейства.

Одним из таких семейств является **степенное семейство** (*power family*). Оно определено для положительных  $X$  и имеет вид:

$$\psi(Y, \lambda) = \begin{cases} Y^\lambda, & \lambda \neq 0 \\ \log(Y), & \lambda = 0 \end{cases}. \quad (6)$$

Семейство параметризовано числом  $\lambda$ , и значение  $\lambda = 0$  принимается не за тождественную единицу (ведь  $Y^0 \equiv 1$ ), а за логарифмическое преобразование  $\log(Y)$ . Здесь возникает проблема, затрудняющая работу с этим семейством – его представители  $\psi(Y, \lambda)$  не являются непрерывным по  $\lambda$ . Поэтому удобнее работать с так называемым **нормированным (или отмасштабированным) степенным семейством** (*scaled power family*):

$$\psi_S(Y, \lambda) = \begin{cases} \frac{Y^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ \log(Y), & \lambda = 0 \end{cases}. \quad (7)$$

Несложно видеть, что  $\psi_S(Y, \lambda)$  и  $\psi(Y, \lambda)$  отличаются только преобразованием сдвига и масштаба, и линейная регрессия будет давать аналогичные результаты при двух этих преобразованиях, отличаться будут только веса предикторов. При этом функция  $\psi_S(Y, \lambda)$  непрерывна по  $\lambda$ , и  $\log(Y)$  является естественным представителем семейства, так как  $\lim_{\lambda \rightarrow 0} \psi_S(y, \lambda) = \log(y) \forall y > 0$ .

Суммируя все вышесказанное, для нахождения оценки  $g^{-1}$  мы рассматриваем модели вида

$$\mathbf{E}(\hat{y}|Y = y) = \hat{\beta}_0 + \hat{\beta}_1 \psi_S(y, \lambda). \quad (8)$$

При фиксированном  $\lambda$  модель (8) представляет собой простую линейную регрессию с предиктором  $\psi_S(y, \lambda)$  и зависимой переменной  $\hat{y}$ . Оптимальным параметром  $\hat{\lambda}$  предлагается считать тот, который минимизирует **остаточную сумму квадратов** (*residual sum of squares*):

$$RSS(\lambda) = \sum_{i=1}^n \left( \hat{y}_i - \hat{\beta}_0 - \hat{\beta}_1 \psi_S(y_i, \lambda) \right)^2. \quad (9)$$

## 2.2 Трансформация только зависимой переменной при помощи преобразования Бокса-Кокса

В своей работе [Box and Cox, 1964] Бокс и Кокс рассматривали модифицированное семейство степенных преобразований:

$$\psi_M(Y, \lambda) = GM(Y)^{1-\lambda} \cdot \psi_S(Y, \lambda) = \begin{cases} GM(Y)^{1-\lambda} \cdot \frac{Y^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ GM(Y) \cdot \log(Y), & \lambda = 0 \end{cases}, \quad (10)$$

где  $GM(Y) = \sqrt[n]{y_1 y_2 \dots y_n}$  – среднее геометрическое выборки.

Метод Бокса-Кокса основывается на предположении, что для некоторого неизвестного  $\lambda$  после преобразования зависимая переменная  $\psi_M(Y, \lambda)$  такова, что  $\psi_M(y_i, \lambda)$  – независимые нормально распределенные сл.в. с постоянной дисперсией  $\sigma^2$  и математическим ожиданием

$$E(\psi_M(Y, \lambda)|X = x) = \beta_0 + \beta_1 x. \quad (11)$$

Из этих предположений предлагается брать такое  $\lambda$ , которое максимизировало бы правдоподобие. В нормальной модели логарифм правдоподобия имеет вид:

$$\begin{aligned} \log(L) = \ell &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 = \\ &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} RSS. \end{aligned} \quad (12)$$

Оценка максимума правдоподобия дает нам  $\hat{\sigma}^2 = RSS/n$ . Отсюда получаем:

$$\ell = -\frac{n}{2} \log(2\pi) - \frac{n}{2} - \frac{n}{2} \log(RSS/n). \quad (13)$$

Можно показать, что якобиан замены преобразования Бокса-Кокса  $\psi_M(Y, \lambda)$  равен 1 при любом  $\lambda$ . А значит при фиксированном  $\lambda$  после трансформации зависимой переменной вид функции правдоподобия останется прежним:

$$\ell(\lambda) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} - \frac{n}{2} \log(RSS(\lambda)/n). \quad (14)$$

Так как только последний член выражения (14) зависит от  $\lambda$ , то решение задачи максимизации правдоподобия  $L(\lambda)$  (или логарифма правдоподобия  $\ell(\lambda)$ ) по  $\lambda$  эквивалентна задаче минимизации  $RSS(\lambda)$  по  $\lambda$ :

$$\ell(\lambda) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} - \frac{n}{2} \log(RSS(\lambda)/n) \rightarrow \max_{\lambda} \Leftrightarrow RSS(\lambda) \rightarrow \min_{\lambda} \quad (15)$$

Здесь и далее для удобства предлагается под преобразованием Бокса-Кокса понимать  $\psi_S(X, \lambda)$  для предикторов и  $\psi_M(Y, \lambda)$  для зависимой переменной. Обозначим его  $\psi_*(U, \lambda)$ .

## Пример

Снова обратимся к сгенерированному примеру из пункта 2.1.1. Из построения нам известно, что искомое значение  $\lambda$  для преобразования  $Y$  равно 0.333. Сравним два метода, которые мы обсудили ранее:

- Inverse response plot выдает оценку  $\hat{\lambda} = 0.341$ ;
- Метод Бокса-Кокса выдает оценку  $\hat{\lambda} = 0.273$ .

В этом конкретном примере метод Бокса-Кокса оказался ощутимо дальше реального значения параметра  $\lambda$ , чем inverse response plot. Однако, как мы увидим далее, преимущество одного метода над другим не так очевидно.

## 2.3 Трансформация только предиктора методом Бокса-Кокса

Мы снова рассмотрим преобразование Бокса-Кокса, на этот раз определенных для строго положительного  $X$ :

$$\psi_*(X, \lambda) = \begin{cases} \frac{X^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ \log(X), & \lambda = 0 \end{cases}. \quad (16)$$

Аналогично пункту 2.2, мы рассматриваем модели вида

$$\mathbf{E}(Y|X = x) = \alpha_0 + \alpha_1 \psi_*(x, \lambda). \quad (17)$$

При фиксированном  $\lambda$  модель (17) представляет собой простую линейную регрессию с предиктором  $\psi_*(x, \lambda)$  и зависимой переменной  $y$ . Аналогично задаче преобразования зависимой переменной, для разных значений  $\lambda$  строится регрессия методом наименьших квадратов (МНК-регрессия) и выбирается то  $\hat{\lambda}$ , которое минимизирует  $RSS(\lambda)$ .

В качестве альтернативы можно использовать вариацию метода Бокса-Кокса, которая пытается сделать распределение преобразованного предиктора  $X$  как можно более нормальным. Заметим, что в этом случае регрессионная модель отсутствует, и метод Бокса-Кокса модифицирован для применения непосредственно к  $X$ .

## 2.4 Трансформация и предиктора, и зависимой переменной

В случае, когда необходимо трансформировать  $Y$  и  $X$ , существует несколько альтернативных подходов. Ниже эти будут сформулированы эти подходы, где необходимо – представлена мотивация подхода, и далее будет проведено практическое сравнение.

Итак, предлагаемые варианты:

1. Попарная минимизация  $RSS$  предикторов из  $\mathbf{X}$  с последующим преобразованием  $Y$  с помощью inverse response plot (если необходимо);

Предлагается для каждого предиктора подобрать преобразование Бокса-Кокса, минимизируя  $RSS$  от регрессии  $Y$  только по этому предиктору. В случае отсутствия корреляций между предикторами, каждый предиктор может быть "улучшен улучшающей полную регрессию  $Y$  по  $\mathbf{X}$ . Иногда может быть полезно трансформировать  $Y$  не после этих действий, а до, например, когда возникает гетероскедастичность.

2. Минимизация определителя матрицы выборочных ковариаций  $|V(\mathbf{X})|$  с последующим преобразованием  $Y$  с помощью inverse response plot;

В работе [Velilla, 1993] предлагается расширить метод Бокса-Кокса на случай многомерных случайных величин. В приложении А показано что-то.

### 3 Заключение

ТВА

## A Многомерное преобразование Бокса-Кокса

Пусть у нас есть многомерная сл.в.  $\mathbf{X} = (X_1, X_2, \dots, X_p)$ . Введем преобразование:

$$\psi_M(\mathbf{X}, \boldsymbol{\lambda}) = (\psi_M(X_1, \lambda_1), \psi_M(X_2, \lambda_2), \dots, \psi_M(X_p, \lambda_p)). \quad (18)$$

Предположим, что существует такое  $\boldsymbol{\lambda}$ , что

$$\psi_M(\mathbf{X}, \boldsymbol{\lambda}) \sim N(\boldsymbol{\mu}, \mathbf{V}), \quad (19)$$

где  $\mathbf{V}$  – некоторая симметричная положительно определенная матрица, которую мы хотим оценить. Если  $\mathbf{x}$  – это наблюдения из распределения  $\mathbf{X}$ , то правдоподобие имеет вид

$$L(\lambda) = \prod_{i=1}^n \frac{1}{(2\pi|\mathbf{V}|)^{1/2}} \exp \left( -\frac{1}{2} (\psi_M(\mathbf{x}_i, \boldsymbol{\lambda}) - \boldsymbol{\mu})^T \mathbf{V}^{-1} (\psi_M(\mathbf{x}_i, \boldsymbol{\lambda}) - \boldsymbol{\mu}) \right), \quad (20)$$

где  $|\mathbf{V}|$  – определитель матрицы  $\mathbf{V}$ . Тогда логарифм правдоподобия имеет вид:

$$\begin{aligned} \log(L(\lambda)) = \ell(\lambda) = & -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(|\mathbf{V}|) - \\ & - \frac{1}{2} \sum_{i=1}^n \left( -\frac{1}{2} (\psi_M(\mathbf{x}_i, \boldsymbol{\lambda}) - \boldsymbol{\mu})^T \mathbf{V}^{-1} (\psi_M(\mathbf{x}_i, \boldsymbol{\lambda}) - \boldsymbol{\mu}) \right). \end{aligned} \quad (21)$$

При фиксированном  $\boldsymbol{\lambda}$  это логарифм правдоподобия многомерного нормального распределения. Мы можем найти оценки максимума правдоподобия для  $\boldsymbol{\mu}$  и  $\mathbf{V}$ :

$$\boldsymbol{\mu}(\boldsymbol{\lambda}) = \frac{1}{n} \sum_{i=1}^n \psi_M(\mathbf{x}_i, \boldsymbol{\lambda});$$

$$\mathbf{V}(\boldsymbol{\lambda}) = \frac{1}{n} \sum_{i=1}^n (\psi_M(\mathbf{x}_i, \boldsymbol{\lambda}) - \mu)(\psi_M(\mathbf{x}_i, \boldsymbol{\lambda}) - \mu))^T.$$

Подставляя эти оценки в (21), получим:

$$\ell(\boldsymbol{\lambda}) = -\frac{n}{2} - \frac{n}{2} \log(2\pi) - \frac{n}{2} \log(|\mathbf{V}(\boldsymbol{\lambda})|) \quad (22)$$

Максимизация (22) по  $\boldsymbol{\lambda}$  равносильна минимизации определителя  $\mathbf{V}(\boldsymbol{\lambda})$  по  $\boldsymbol{\lambda}$ .

## B Графики

### Список литературы

- [Berger and Casella, 2001] Berger, R. and Casella, G. (2001). Statistical Inference. Duxbury Press, Florence, AL, 2 edition.
- [Box and Cox, 1964] Box, G. E. P. and Cox, D. R. (1964). An analysis of transformations. Journal of the Royal Statistical Society. Series B (Methodological), 26(2):211–252.
- [Cook and Weisberg, 1994] Cook, R. D. and Weisberg, S. (1994). Transforming a response variable for linearity. Biometrika, 81(4):731–737.
- [Velilla, 1993] Velilla, S. (1993). A note on the multivariate Box–Cox transformation to normality. Statistics & Probability Letters, 17(4):259–263.
- [Weisberg et al., 1978] Weisberg, H., Beier, E., Brody, H., Patton, R., Raychaudhuri, K., Takeda, H., Thern, R., and Van Berg, R. (1978).  $s$ -dependence of proton fragmentation by hadrons. ii. incident laboratory momenta 30–250 gev/c. Phys. Rev. D, 17:2875–2887.